Теоретическая информатика

Конспект лекций

Содержание

1 Информация и данные **2**

1.1 Система передачи информации 2

2 Дискретные и непрерывные сигнальные каналы **3**

2.1 Дискретизация 3

3 Мера информации **4**

3.1 Вероятность событий 4

3.2 Мера информации Хартли 4

3.3 Энтропия 4

4 Системы счисления **6**

4.1 Число и его модель 6

4.2 Система счисления. Определение и характеристики 6

4.3 Позиционные и непозиционные системы счисления 7

4.4 Позиционное и полиномиальное представление чисел 7

4.5 Двоичная, десятичная, шестнадцатеричная системы счисления 7

4.6 Преобразование чисел из одной системы счисления в другую 8

5 Представление чисел, символов, графических и звуковых данных в ЭВМ **8**

5.1 Представление целых чисел в ЭВМ 8

5.2 Прямой и дополнительный коды представления двоичных чисел 9

5.3 Операции с целыми числами 9

1. Информация и данные

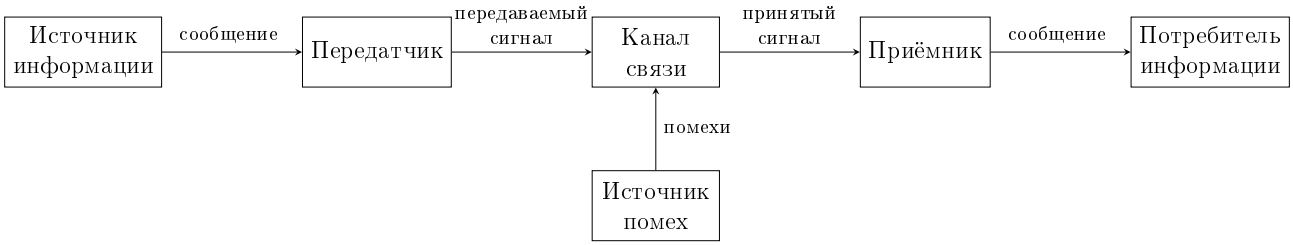
Определение. *Информация* — это совокупность сведений, полученных путём наблюдения и изучения, расширяющих представление об объектах, явлениях окружающей среды, их свойствах, состоянии и взаимосвязях.

Определение. *Данные* — это информация в форме, пригодной для её хранения, обработки, передачи.

Основоположник теории информации — **Шеннон**.

1.1. Система передачи информации

Обмен информацией происходит между людьми, между людьми и окружающим миром. Информацию передаёт какой-либо объект, система.



Источник отправляет информацию в виде сообщения.

Определение. *Сообщение* — это форма представления информации для её непосредственной передачи в виде данных.

Формы сообщений:

- текстовая — текст на естественном языке;
- кодовая — закодированные данные;
- графическая — изображения объектов;
- звуковая;
- видео;
- сигналы.

Передатчик преобразует сообщение в сигналы, пригодные для передачи по каналу связи. Например, в мобильной телефонии передатчик преобразует звуковое сообщение в радиосигналы.

Определение. *Сигнал* (в общем случае) — это физический динамический процесс, при котором его параметры изменяются во времени.

Определение. *Канал связи* — это физическая среда, используемая для передачи сигнала от передатчика к приёмнику. Каналом может быть коаксиальный кабель, полоса радиочастот, луч света и т. д.

Приёмник обычно выполняет преобразование, обратное преобразованию, проводимому передатчиком. Восстанавливает сообщение из сигнала.

Потребитель информации — это человек или устройство, для которого предназначено сообщение.

Чаще всего при передаче сигнала эти сигналы могут быть искажены помехами. **Источник помех**

действует на передаваемые сигналы, изменяя принимаемое сообщение.

Система передачи информации проявляется в различных сферах нашей жизни:

Части	**Лекция**	**Запрос веб-сервера (ВС)**	**Телевидение**
Источник информации	Лектор	Клиентский компьютер (КК)	Источник радиосигнала
Передатчик	Голосовые связки лектора	Сетевая плата КК	Радиоканал
Канал связи	Воздушная среда	Провайдер, канал связи (ПКС)	Воздух, радиоканал
Приёмник	Уши	Сетевая плата	Антенна радиоприёмника
Потребитель информации	Студент	ВС	Слушатель
Источник помех	Шум в аудитории, уличный шум	Воздействие на ПКС	Атмосферные шумы
Сообщение	Текст	Текстовое или числовое	Видеоизображение

2. Дискретные и непрерывные сигнальные каналы

> **Определение.** Если параметр сигнала принимает конечное число значений и при этом они все могут быть пронумерованы, то этот сигнал называется *дискретным*. Канал для передачи таких сигналов также называется дискретным.

Примером дискретных сигналов являются буквы. Количество букв конечно, и их можно рассматривать как уровни сигнала передачи сообщения.

> **Определение.** Если параметр сигнала является непрерывной во времени функцией, то сигнал называется *непрерывным*. Канал для передачи непрерывных сигналов называется непрерывным.

Пример. Человеческая речь — передаваемая звуковой волной, характеризуемой частотой, фазой и амплитудой. Параметром сигнала в этом случае является давление, создаваемое этой волной в точке нахождения приёмника — человеческого уха.

Для передачи информации используются непрерывные и дискретные каналы связи. Сигналы переводят из непрерывных в дискретные и обратно.

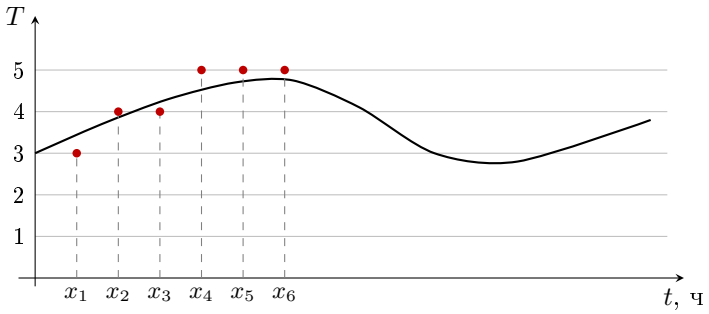
2.1. Дискретизация

> **Определение.** *Дискретизация* — это процесс преобразования непрерывного сигнала в дискретный с конечным числом значений на определённом отрезке.

Для этого диапазон значений функции (ось ординат) разбивается на конечное число отрезков равной ширины, называемой *шагом дискретизации*. Дискретное значение определяется отрезком, в который попало непрерывное значение функции.

! Чем меньше шаг дискретизации, тем ближе полученный дискретный сигнал к исходному непрерывному сигналу, следовательно, больше степень дискретизации.

Пример. На метеостанции каждые полчаса производят замер температуры.



Непрерывно меняющаяся температура замеряется в моменты $x_1, x_2, \ldots$; в журнал записываются значения, являющиеся дискретными значениями. В этом примере получасовой промежуток является шагом дискретизации по времени, шаг дискретизации по значению равен 1, т. к. производится округление до целого числа, а получасовые замеры температуры являются процессом дискретизации.

3. Мера информации

3.1. Вероятность событий

$$P = \frac{m}{N}, \qquad 0 \le P \le 1; \qquad\qquad P_i = \frac{m_i}{N}, \qquad \sum_{i=1}^{n} P_i = 1.$$

3.2. Мера информации Хартли

Пусть система находится в одном из n состояний в каждый момент времени, причём каждое из состояний равновероятно. Например, в качестве системы могут выступать опыты с подбрасыванием монеты ($n = 2$) или бросанием игральной кости ($n = 6$). Система может хранить количество единиц информации, исчисляемое количеством состояний, по формуле Хартли:

$$\boxed{H = \log_b n = \frac{\ln n}{\ln b}}$$

Основание b определяет единицу измерения информации. При $b = 2$, $n = 2$ имеем $H = 1$ — количество информации минимально, поэтому в качестве единицы информации принимают два равновероятных состояния системы, например «ложь» — «истина».

Определение. Такая единица количества информации называется *бит* (*bit* — *binary digit*).

3.3. Энтропия

Определение. *Энтропия* — мера информации Шеннона (рассматривается среда передачи информации с дискретным каналом без помех). Пусть в сообщениях используются символы алфавита A с вероятностями $(p_1, p_2, \ldots, p_n)$. Мера информации, которую в среднем несёт символ алфавита, называется *энтропией* H этого алфавита. Энтропия определяется формулой

$$H = \sum_{i=1}^{n} p_i \log_2 \frac{1}{p_i} = -\sum_{i=1}^{n} p_i \log_2 p_i.$$

Смысл энтропии может быть рассмотрен в различных аспектах:

1) неопределённость для получателя информации, какой символ будет передан, о чём будет сообщение;
2) объём информации, создаваемый источником, или среднее количество бит, требуемое для кодирования алфавита A.

Свойства энтропии:

1) энтропия измеряется в битах на символ;
2) энтропия максимальна, если состояния системы равновероятны;
3) если вероятность одного символа равна единице, а остальных — 0, то энтропия равна 0: получатель заранее знает получаемые символы, и неопределённость равна 0.

Применения энтропии:

1) **Основная теорема Шеннона для канала без шума.**

> **Теорема (Шеннона).** Пусть источник имеет энтропию H (бит на символ), а канал имеет пропускную способность C (бит в секунду). Тогда можно закодировать сообщение таким образом, чтобы передавать символы по каналу со средней скоростью
>
> $$\frac{C}{H} - \varepsilon \quad \text{(символов в секунду)},$$
>
> где ε сколь угодно мало. Со средней скоростью больше, чем $\dfrac{C}{H}$, невозможно.

   Для приближения к этому пределу необходимо более частые символы представлять более короткими кодами.

2) **Относительная энтропия.**

> **Определение.** Отношение энтропии к максимальному значению, которое могла бы достичь энтропия при тех же символах, называется *относительной энтропией*.

   Относительная энтропия является мерой максимального сжатия информации, которое достигается кодированием при помощи того же самого алфавита. Единица минус относительная энтропия есть *избыточность*. Избыточность обычного английского текста составляет примерно 50%.

3) **Энтропия определяет степень сжатия символьными кодами.** Символьные коды представляют исходный алфавит так, чтобы обеспечить максимальное сжатие. Пусть элементы сообщения кодируются кодами длины $(l_1, l_2, \ldots, l_n)$. *Ожидаемая длина кода* определяется по формуле

$$L = \sum_{i=1}^{n} p_i l_i.$$

   Ожидаемая длина кода ограничена энтропией: $\boxed{H \leq L < H + 1}$.

Пример. В сообщении используются независимые буквы A, B, C, D с вероятностями $\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}$.

$$H = -\left(\tfrac{1}{2}\log_2\tfrac{1}{2} + \tfrac{1}{4}\log_2\tfrac{1}{4} + \tfrac{1}{8}\log_2\tfrac{1}{8} + \tfrac{1}{8}\log_2\tfrac{1}{8}\right) = \frac{7}{4} = 1{,}75 \text{ бит на символ.}$$

Максимальная энтропия для букв A, B, C, D: $H_{\max} = \log_2 4 = 2$ при их вероятностях $\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}$.

Относительная энтропия: $\dfrac{H}{H_{\max}} = \dfrac{1{,}75}{2} = 0{,}875$, а избыточность: $1 - \dfrac{H}{H_{\max}} = 0{,}125$.

Зададим коды букв двумя способами:

1) с учётом их вероятности (более частые буквы кодируются более короткими кодами);
2) без учёта.

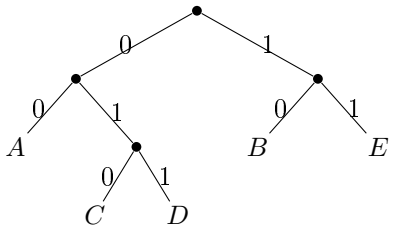
Буква	Способ 1 (с учётом)	Способ 2 (без учёта)
A	0	00
B	10	01
C	111	10
D	110	11

Ожидаемая длина кода $L = \sum p_i l_i$:

$$L_1 = \tfrac{1}{2} \cdot 1 + \tfrac{1}{4} \cdot 2 + \tfrac{1}{8} \cdot 3 + \tfrac{1}{8} \cdot 3 = \tfrac{7}{4}, \qquad L_2 = \tfrac{1}{2} \cdot 2 + \tfrac{1}{4} \cdot 2 + \tfrac{1}{8} \cdot 2 + \tfrac{1}{8} \cdot 2 = 2.$$

Первый способ достигает нижней границы: $L_1 = H$.

Пример. Буквы A, B, C, D, E с вероятностями 0,3; 0,35; 0,1; 0,1; 0,15. Коды строятся по дереву: на каждом ветвлении левой ветви приписывается 0, правой — 1.



Буква	p_i	Код
A	0,3	00
B	0,35	10
C	0,1	010
D	0,1	011
E	0,15	11

Самостоятельно: объёмный подход (раздел 2.4.2), разделы 2.5 и 2.3.

4. Системы счисления

4.1. Число и его модель

Числа занимают важную часть современного мира:

1) результаты измерений обычно записываются числами;
2) в ЭВМ (электронной вычислительной машине) обработка данных сведена к вычислениям. Исходными и конечными данными вычислений являются числа.

В природе количество чисел не ограничено, однако практические модели содержат конечное количество чисел. Например, в ЭВМ могут храниться очень большие числа, но их диапазон ограничен. Наиболее точной моделью числа является его запись. Запись числа необходима для его запоминания.

4.2. Система счисления. Определение и характеристики

Числа записываются в системе счисления.

Определение. *Система счисления* — это соглашение о представлении чисел посредством конечной совокупности символов (цифр)

$$A = \{a_1, a_2, \ldots, a_n\}.$$

A называется *алфавитом*; каждой цифре ставится соответствие, определяющее её количественный эквивалент.

Люди используют десятичную систему счисления, а ЭВМ — двоичную (устройства с двумя состояниями проще).

Характеристиками системы счисления являются:

1) отличимость символов;
2) вычислимость чисел;
3) выявляемость ошибок в записи.

Одна и та же система счисления имеет разные показатели характеристик для человека и ЭВМ. Например, вычисления в двоичной системе счисления для ЭВМ проще, чем для человека, а в десятичной — наоборот.

4.3. Позиционные и непозиционные системы счисления

Системы счисления разделяют на позиционные и непозиционные.

Определение. *Непозиционные системы счисления* — это системы, в которых цифры не меняют своего количественного эквивалента в зависимости от местоположения (позиции) в записи числа.

К непозиционным системам счисления относится система римских цифр.

Определение. *Позиционные системы счисления* — это системы, в которых количественный эквивалент цифры зависит от её положения в числе.

Пример — десятичная система счисления.

Определение. *Основание* позиционной системы счисления — это количество символов в её алфавите. Позиционные системы счисления с основанием n называют *n-ичными*.

В десятичной СС 10 цифр, поэтому она имеет основание $n = 10$.

! Преимущество позиционной СС: для записи числа K необходимо не более $\lfloor \log_n K \rfloor + 1$ цифр. Операции над числами сводятся к действиям над его цифрами.

Далее рассматриваются только позиционные системы счисления, поэтому слово «позиционная» опускается.

4.4. Позиционное и полиномиальное представление чисел

Пример. Полином: $a_0x^0 + a_1x^1 + a_2x^2 + \cdots + a_nx^n$, например $2x^3 + 4x + 5$.

Определение. *Позиционное представление* числа B_n с целой и дробной частью в n-ичной СС имеет форму

$$B_n = a_m a_{m-1} \dots a_1 a_0, \, a_{-1} a_{-2} \dots a_{-k},$$

запятая разделяет целую (слева) и дробную (справа) части; a_i, $i = -k, \dots, m$ — цифра в позиции i; n — явное указание основания системы счисления.

Определение. *Полиномиальное представление* B_n имеет вид суммы произведений цифр на вес их позиции в числе:

$$B_n = a_m n^m + a_{m-1} n^{m-1} + \cdots + a_1 n^1 + a_0 n^0 + a_{-1} n^{-1} + a_{-2} n^{-2} + \cdots + a_{-k} n^{-k} = \sum_{i=-k}^{m} a_i n^i. \quad (4.1)$$

! Позиционное представление определяет запись (вид числа), а полиномиальное — значение числа.

4.5. Двоичная, десятичная, шестнадцатеричная системы счисления

В информатике используются следующие системы счисления:

1) двоичная: $n = 2$, алфавит $A = \{0, 1\}$;
2) десятичная: $n = 10$, алфавит $A = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$;
3) шестнадцатеричная: $n = 16$, алфавит $A = \{0, 1, \dots, 9, A, B, C, D, E, F\}$.

Д/з: DRAM-память (посмотреть в интернете).

В вычислительной технике используется двоичная система счисления. Все числа и данные представляются в виде последовательности $\{0, 1\}$ (бит). Двоичная СС обладает следующими преимуществами перед СС с другими основаниями:

1) Для хранения двоичных цифр необходимы технические устройства с двумя устойчивыми состояниями, которые легко различимы. Например: ток есть — ток отсутствует, намагничено —

не намагничено и т. п.

2) Представление данных посредством только двух состояний надёжно и помехоустойчиво.



Помехоустойчивость — к данным добавляются контрольные разряды (контрольная сумма CRC, бит чётности). Если данные чётные и бит чётности чётный, то всё OK.

3) Для выполнения арифметических операций используется простой аппарат логики высказываний (булевой алгебры).

Шестнадцатеричная система счисления используется для сокращения записи чисел в двоичной СС.

4.6. Преобразование чисел из одной системы счисления в другую

В вычислительной технике ввод, вывод и обработка числовых данных связаны с преобразованием чисел из одной СС в другую.

> **Правило 4.1** (преобразование целого или дробного числа из n-ичной СС в десятичную). Число из n-ичной СС преобразуется в десятичную СС по формуле (4.1).

Пример. $11001_2 = 1 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 = 16 + 8 + 1 = 25_{10}$.

При преобразовании из одной СС в другую (недесятичную) правила преобразования различаются для целых и дробных чисел.

> **Правило 4.2** (преобразование целых чисел из 10-ичной СС в n-ичную). Целое число X преобразуется в n-ичную СС по следующему алгоритму:
> 1) получить цифру числа n-ичной СС как остаток деления числа X на основание новой СС n; полученную цифру записать слева от предыдущих цифр;
> 2) принять за X частное от деления числа X на основание СС n;
> 3) выполнять пп. 1), 2), пока $X \neq 0$.

Пример 4.3. Перевести 25 в СС с $n = 2$.

$$\begin{array}{rcll} 25:2 & = & 12, & \text{остаток } 1 \\ 12:2 & = & 6, & \text{остаток } 0 \\ 6:2 & = & 3, & \text{остаток } 0 \\ 3:2 & = & 1, & \text{остаток } 1 \\ 1:2 & = & 0, & \text{остаток } 1 \end{array} \qquad \Longrightarrow \qquad 25_{10} = 11001_2$$

(остатки записываются справа налево: последний остаток — старшая цифра).

Самостоятельно: преобразование дробных чисел из одной СС в другую.

5. Представление чисел, символов, графических и звуковых данных в ЭВМ

5.1. Представление целых чисел в ЭВМ

Целые числа — универсальный способ представления вещественных чисел, точек изображения и звука: форматы представления вещественных чисел, точек изображения, звука используют целые числа как базовый элемент.

Форматы представления целых чисел. Числа в ЭВМ хранятся в соответствии с форматами.

> **Определение.** *Формат* — это соглашение или правило представления числа как последовательности разрядов.

Минимальная единица хранения данных в ЭВМ — 1 байт.

В настоящее время в 32-разрядных ЭВМ существуют следующие форматы представления целых чисел: *байт*, *полуслово* (2 байта), *слово* (4 байта), *двойное слово* (8 байт). Биты, составляющие эти форматы, называются *разрядами*. Слева — старшие разряды, справа — младшие.

Каждый из этих форматов может быть *знаковым* для представления положительных или отрицательных чисел, или *беззнаковым* для представления положительных чисел. Знаковым является самый старший разряд: если разряд $= 0$, то число положительное, если разряд $= 1$, то число отрицательное.

В формате целых чисел размером больше 1 байта числа хранятся в памяти ЭВМ в обратном порядке: вначале младший байт, потом старший.

Пример. Число $\mathrm{B5DE}_{16}$ хранится как $\boxed{\mathrm{DE}}\boxed{\mathrm{B5}}$.

Такое расположение байт ускоряет операции с числами, т. к. вычисления по алгоритмам начинаются с младших разрядов.

5.2. Прямой и дополнительный коды представления двоичных чисел

1) В *прямом коде* старший бит кодирует знак числа (0 для «+», 1 для «−»), а остальные биты — модуль числа.
   Пример. (знаковый бит отделён чертой) $\quad 11_{10} = 0|1011_{\text{п}}, \qquad -11_{10} = 1|1011_{\text{п}}.$
2) В *дополнительном коде* положительные числа кодируются так же, как и в прямом. Для преобразования отрицательного числа в дополнительный код есть 2 способа.

> **Определение.** Операция *инвертирования* — замена значения разряда на противоположное.

> **Правило 5.1** (поразрядное представление числа в дополнительном коде). Представить модуль отрицательного числа в прямом коде и проинвертировать все разряды левее самой младшей (правой) единицы.

Пример. Представить число -11_{10} в дополнительном коде:

$$|-11| = 0|1011 \quad \xrightarrow{\text{инвертируем всё левее младшей единицы}} \quad 10101 = -11_{10}.$$

> **Правило 5.2** (арифметическое представление отрицательного числа в дополнительном коде). Прибавить к отрицательному числу 2^m, где m — количество разрядов в двоичном представлении или данном формате, и полученное число перевести в двоичную СС. Для байта $2^8 = 256$.

! Из этих правил следует, что положительные числа в случае увеличения числа разрядов дополняются слева нулями, а отрицательные — единицами.

Пример. Представить -11_{10} в дополнительном коде ($m = 5$):

$$2^5 = 32 \;\Rightarrow\; -11 + 32 = 21, \qquad 21_{10} = 10101_2.$$

Взаимно обратное преобразование отрицательных чисел и чисел, записанных в дополнительном коде, выполняется по тем же правилам.

5.3. Операции с целыми числами

Центральный процессор ЭВМ только складывает и выполняет операции с разрядами (логические — конъюнкция, дизъюнкция, инвертирование, сдвиг). Поэтому все арифметические операции сводятся к сложению.

Запись в дополнительном коде используется для сложения и вычитания положительных и отрицательных чисел без преобразования.

Пример. Сложить 21_{10} и -11_{10} (6 разрядов):

$$\begin{array}{rl} 010101 & (21_{10}) \\ +\ 110101 & (-11_{10}) \\ \hline \not{1}001010 = 10_{10} & \end{array}$$

(перенос из старшего разряда отбрасывается).

При умножении чисел используется *модифицированный алгоритм Бута*. Множители представлены в дополнительном коде.

Правило 5.6 (модифицированный алгоритм Бута). Числа умножаются следующим образом:

1) Разделить второй множитель справа налево на перекрывающиеся триады. Триады должны перекрываться в одном разряде. Если правая триада не полная, то дополнить её нулями.
2) Заменить триады на коды операций:

Триада	Код
000	0
001	+1
010	+1
011	+2
100	−2
101	−1
110	−1
111	0

3) Для каждого полученного кода определить слагаемое как результат операции с первым множителем:

Код	Операция с множителем
−2	получить дополнительный код и умножить на 2 (сдвиг на 1 бит влево)
−1	получить дополнительный код
0	сформировать строку из нулей
+1	не изменять
+2	умножить на 2 (сдвиг на 1 бит влево)

4) Сдвинуть каждое слагаемое влево на 2 разряда относительно предыдущего и сложить слагаемые. Для множителя из k разрядов необходимо получить $\frac{k}{2}$ слагаемых.

Пример. Умножить -11_{10} на 29_{10}.

$$-11_{10} = 10101_2 \text{ (дополнительный код)}, \qquad 29_{10} = 011101\underline{0}_2 \text{ (дописан ноль справа)}.$$

Триады справа налево: $010 \to +1,\ 110 \to -1,\ 011 \to +2$.

Слагаемые (10 разрядов, каждое следующее сдвинуто на 2 разряда влево):

$$\begin{array}{rl} 1111110101 & (+1:\ -11) \\ +\ 0000101100 & (-1:\ +11,\ \text{сдвиг на } 2) \\ +\ 1010100000 & (+2:\ -22,\ \text{сдвиг на } 4) \\ \hline 1011000001 & = -319_{10} \end{array}$$

Проверка: модуль результата $0100111111_2 = 319_{10}$, и $-11 \cdot 29 = -319$.

При операциях с целыми числами возможно *переполнение* или *переполнение снизу*:

- *переполнение* (overflow) возникает при больших значениях представленного числа;
- *переполнение снизу* (underflow) возникает при результате операции меньшем, чем представимое число.